

Identifikacija raka dojke na slikama mamografije

Jakov Krčadinac, Tamara Ćorić, Lucija Ćorak,
Martina Šola, Domagoj Marić

Projekt iz kolegija Analiza slike u biomedicini

Fakultet elektrotehnike i računarstva, Zagreb 2025.

Rak dojke


- Bolest pri kojoj abnormalne stanice dojke nekontrolirano rastu i stvaraju tumore
- Najčešće obolijevaju žene iznad pedesete godine života
- Može se dijagnosticirati putem:
 1. mamografije, rendgenskog pregleda dojki kojim se otkrivaju tumori i druge promjene dojke koje su premalene da bi se mogle napipati
 2. ultrazvuka, neškodljive radiološke dijagnostičke metode koja pomoću visokofrekventnog zvuka može procijeniti morfologiju, orijentaciju, unutarnju strukturu i rubove lezije iz više ravnina s visokom rezolucijom

Korišteni skup podataka


- Javno dostupan skup podataka *CBIS-DDSM: Breast Cancer Image*
 - 10 000 rendgenskih slika s mamografije
 - 1566 pacijenata
 - Patologija: maligno, benigno i benigno tkivo za koje nisu potrebni daljnji učestali pregledi
 - Originalne snimke, izrezani manji dijelovi originalne slike i ROI maske
 - Svaki pacijent je samo u jednom skupu, skupu za treniranje ili skupu za testiranje
- Korištene samo izrezane slike manjih dimenzija na kojima su već izdvojena područja interesa
 - Originalne snimke su prevelike koje bi usporile učenje i otežale izradu modela
 - ROI maske ne sadrže nikakve korisne informacije je li prikazano tkivo maligno
 - Nažalost nije bilo moguće razlikovati koje su datoteke u podatkovnom skupu ROI maske, a koje izrezane slike zbog nekonzistentnog imenovanja
 - Zbog toga smo morali iz podatkovnog skupa odvojiti izrezane slike na temelju dimenzija

Automatizirana ekstrakcija izrezanih slika na temelju dimenzija

- Vidljivo je da su izrezane slike uvijek znatno manjih dimenzija od ROI maski koje imaju dimenzije originalne slike
- Izrezana slika i ROI maska se nalaze u istoj mapi, program prolazi kroz svaku mapu i uzima samo sliku manjih dimenzija (izrezanu) te ju sprema u konačni podatkovni skup
- Konačni podatkovni skup sada ima manje od 200MB, dok je preuzeti podatkovni skup koji uključuje originalne slike i ROI maske imao preko 11GB





Dimenzije 1546 izrezanih slika i ROI maski u skupu za treniranje



Dimenzije 326 izrezanih slika i ROI maski u skupu za testiranje

- Razdioba vrijednosti značajke Pathology na skupovima za treniranje i testiranje



Rješenje problema

- Biblioteke: PyTorch, pandas, torch.nn
- Podaci učitani iz CSV datoteka pomoću prilagođene klase *BreastCancerDataset* koja omogućuje učitavanje i transformaciju slike uz povezivanje s pripadajućom klasifikacijom
- Usporedba dva pristupa:
 1. Treniranje modela od nule
 2. Korištenje unaprijed istreniranih modela

Treniranje od nule

- Klasa CNN
 - Dva bloka konvolucijskih slojeva → blok = 2 konvolucijska sloja + 2 sloja za normalizaciju
 - *ReLU* kao aktivacijska funkcija za sve slojeve
 - Na kraju svakog bloka su implementirani slojevi za smanjenje dimenzionalnosti (*MaxPool*)
 - Izlazi su izravnati u jednodimenzionalni tenzor te proslijeđeni kroz dva potpuno povezana sloja, čiji konačni izlaz odgovara broju klasa (3)
 - *ReduceLROnPlateau* za izbjegavanje stagnacije tijekom treniranja modela
- SimpleCNN
 - Jednostavniji model (sprječavanje prenaučivosti)
 - 4 konvolucijska sloja
- *Adam* algoritam uz definiranu stopu učenja i regularizaciju → optimizacija modela
- *CrossEntropyLoss* za računanje gubitka i *accuracy_score* za procjenu uspješnosti modela prilikom treninga i validacije

Prethodno treniran model


- ResNet
 - 18 slojeva
 - Prethodno treniran na skupu slika *ImageNet*
 - Kao ulaz prima RGB slike dimenzija 224x224 → prilagođene dimenzije korištenog skupa podataka, normalizirana transformacija
 - Promijenjena dimenzionalnost ulaznog sloja zbog slika u sivim tonovima koje se nalaze u korištenom datasetu
- *Adam* algoritam za optimizaciju modela
- *accuracy_score* za procjenu uspješnosti modela prilikom treninga i validacije

Eksperimentalni rezultati

- 80% podataka za treniranje, 20% podataka za testiranje

- ***Konvolucijska neuronska mreža, CNN***

- 20 epoha treniranja
- Gubitak preko 65%
- Točnost oko između **58% i 62%**
- Weighted average F-1 score: 0.58
- Maligne uzorke zna pogrešno klasificirati kao benigne



Slika 6. Prikaz konfuzijske matrice

Eksperimentalni rezultati

- *Prethodno treniran model, ResNet*

- 10 epoha treniranja
- Gubitak veći od 90%
- Točnost oko 50%

- *Jednostavnija konvolucijska neuronska mreža, Simple CNN*

- 4 konvolucijska sloja
- 20 epoha treniranja
- Gubitak oko 80%
- Točnost oko 54%
- Relativno sklon prenuaćenosti

Usporedba naših rezultata s rezultatima prethodnih radova

Diagnosis in Two-View Mammography Using End-to-End Trained EfficientNet-Based CNN

- 85,13% točnosti (5-fold cross-validation)
- Model EfficientNet (visoka robusnost, generalizacija, napredna arhitektura)
- Učitavane slike su većih dimenzije (očuvani detalji)
- Isključene slike BENIGN_WITHOUT_CALLBACK + klasifikacija BENIGN_WITHOUT_CALLBACK promijenjena u BENIGN
- Postoje mnogo manje vizualne razlike između izrezanih slika koje su označene kao BENIGN_WITHOUT_CALLBACK i BENIGN
- Reklasifikacija slika na ovaj način bi vjerojatno poboljšala preciznost našeg modela

Usporedba naših rezultata s rezultatima prethodnih radova

Prethodni radovi na Kaggle platformi

- Dva rada s visokom točnošću ~90%
- Skup *CBIS-DDSM* korišten samo za demonstraciju ROI maski i vizualnog procesiranja CNN-a, a ne za treniranje
- CNN modeli trenirani na različitom skupu podataka (*Breast Histopathology Images*).

Zaključak

- Cilj projekta je bio postići preciznu klasifikaciju slika mamografije dojki koje prikazuju maligne ili benigne promjene te promjene koje ne prikazuju tumor vrijedan daljnjeg praćenja
- Korišteno je nekoliko implementacija CNN-a različitih kompleksnosti
 - Najsofisticiraniji i najjednostavniji model podjednako dobro klasificiraju (54%)
 - Srednje komplicirana instanca CNN-a najuspješnije klasificira (58-62%)
- Moguća bolja klasifikacija korištenjem robusnijeg algoritma kao što je 'EfficientNet' ili podjelom skupa podataka na binarnu klasifikaciju (BENIGN, MALIGNANT)
- Vrijedilo bi istražiti klasificiranje alternativnog skupa podataka s histopatološkim slikama uzoraka tkiva dojke